

项目	内容
文档版本	v1.0
编制日期	2026-09-03
文档性质	技术设计方案（对应一期交付形态 + 二期演进）
适用读者	研发、运维、评审与接手维护人员
配套文档	《SEU 科研工作台项目策划书》《用户手册》《模板编写指南》、BASE-CHANGES-REGISTRY（BC-1~12）

1. 设计概述

1.1 设计目标


在多 Agent 本地运行时基座之上，构建面向科研场景的一站式工作台。设计围绕三条主线展开：

- 确定性工作流**：将科研方法固化为"确定性脚本为主、大模型为辅"的 DAG 流程，保证过程可复现、可中断续跑、失败可见；
- 论文工作台**：文献、翻译、写作、产物四类资产的本地化管理与流式访问；
- 智能协同**：以聊天为协同载体，提供带引用溯源的知识库问答与沙箱化的富内容渲染。


1.2 设计约束

约束	说明
基座同源	基座代码与上游仓库同源，自研改动必须附加式、向后兼容，并逐条登记（BC 机制），保证上游可合并
模块边界	服务端按业务域分模块（studio/research/hermes/ekko/coding-agents），模块间仅允许经 public 门面调用，由边界检查脚本强制
API-first	智能能力全部经 OpenAI 兼容 API 接入，不本地运行模型权重；密钥仅经环境变量传递
零冗余依赖	前端渲染能力（mermaid/KaTeX/highlight.js）复用基座既有依赖，自研部分零新增 npm 依赖
运行环境	Node.js ≥ 23 ；Windows 为一等公民（进程树终止、路径语义、盘符与 ADS 防御均显式处理）

2.1 系统组成



系统自上而下分为六层，要点如下（完整拓扑见上图）：



2.2 技术栈

SEU 科研工作台

层	技术
前端	Vue 3 (<code><script setup></code>) 、Naive UI、Pinia、Vue Router、Vue Flow (DAG 画布)、markdown-it + highlight.js + mermaid + KaTeX
后端	Node.js $\geq$ 23、Koa、@koa/router、Socket.IO、node:sqlite、nodemon (开发热载)
sidecar	Python 3.12 (pdf2zh-next 2.9.0、paper-qa 2026.8.12、python-pptx 1.0.2) 、tectonic 0.17.0
质量	Vitest (单元/组件/服务端集成)、Playwright (端到端)、模块边界检查脚本、harness 检查

2.3 请求与数据流

- 页面数据**: 浏览器 $\rightarrow$ Koa 路由 (JWT 鉴权, 注册于代理 catch-all 之前) $\rightarrow$ 控制器 $\rightarrow$ 服务 $\rightarrow$ 各域自有 SQLite/文件存储;
- 会话运行**: 浏览器 $\leftrightarrow$ Socket.IO $\rightarrow$ 引擎调度 (agent 节点经聊天运行时、确定性节点经执行器子进程) ;
- 文件流**: PDF/产物统一经支持 HTTP Range (单区间 206/416 语义) 的流式端点输出, 供浏览器原生查看器渐进加载。

3. 确定性 workflow 引擎 (核心设计)

3.1 节点模型

节点类型	执行者	会话	职责
agent	聊天运行时 (大模型)	✓	理解与写作; 可绑定技能 (注入 SKILL.md 全文到提示词)
script	确定性执行器 (真实 Node 子进程)	✗	机械环节: 校验、聚合、报告生成、文件处理
validate / render	执行器 (一期为显式占位)	✗	校验/渲染类扩展位

脚本五字段契约: 每个 script 节点必须且只能声明 `title / input / orchestration / runtime('node') / code`。引擎加载时对缺失 runtime 的历史数据做显式失效标记 (不静默改写), 保存前做确定性专属校验, 未知节点类型显式拒绝。

3.2 执行生命周期与资源安全

确定性节点执行遵循严格的资源安全模型 (BC-5 加固后形态) :

- 停止传播**: `stopRun` 为每个确定性节点建立 AbortController, 经运行时契约将 `AbortSignal` 传入执行器; `deadline` 超时同样先 abort 再失败。信号到达即终止**整棵进程树** (Windows 走 `taskkill /T /F`, POSIX 直接 kill) 。
- 输出上限**: stdout/stderr 各设 5MB 硬上限, 超限立即杀树并以结构化错误结算 (杜绝内存膨胀型失控脚本) 。
- 单次结算**: abort/超时/超限/正常退出统一经幂等结算闸门, 保证节点行只写一次终态。
- rerun 防护**: 重跑与首跑共用 workflow 运行许可 (admission), 终态复位采用 `UPDATE ... WHERE status=?` 原子 CAS (影响行数 $\neq$ 1 即 409), 执行标识改用随机 UUID 避免唯一索引冲突。
- 输出落盘**: 脚本 stdout 即节点输出, 落 `output_json` 列 (必填字符串), 重跑恢复与运行详情均从该列读取。

3.3 模板契约与输入协议

- 模板契约**: 节点调色板白名单、script 五字段精确校验、agent 字段全有或全无、单入口 + 全节点可达、技能绑定合法性;
- 引擎输入协议**: 引擎将上游输出包装为 `[Workflow upstream results] / [Upstream: <节点标题>] / [Current task]` 段落后注入 stdin。脚本侧提供两级标准处理:
 - `stripEngineWrapperLines()`: 剥除全部包装行后再解析 (入口/报告类节点) ;

- `splitUpstreamSections()`: 按 `[Upstream: ...]` 头分节后逐节处理（菱形汇聚节点），支持按内容形态识别节、与标题无关。

SEU 科研工作台
- 模板 e2e 测试统一采用"mock 智能层 + 真实确定性执行器"模式: script 节点由真实 Node 子进程执行，外部二进制以契约兼容的包装脚本替身，断言运行终态、产物落盘与"无包装行泄漏"。

3.4 快照与恢复

运行启动时冻结节点/边快照；确定性输出持久化后，画布回放与中断续跑（rerun-from-node）以快照 + `output_json` 还原现场，上游缺失输出时 fail-closed（409）。

4. 科研功能模块设计

4.1 文献库（library/papers）

- **存储**: 元数据 SQLite（<状态目录>/research/papers.db），PDF 字节以 UUID 命名落盘（用户输入不接触文件系统路径）；
- **流式预览**: `GET /papers/:id/file` 支持 HTTP Range（单区间 206、后缀区间、超 EOF 钳制、越界 416 bytes */size、非法/多区间回落 200、HEAD 仅元数据不开流）——大 PDF 由浏览器原生查看器按需拉取；
- **脱敏视图**: 对外响应统一经 `PaperView` 序列化层，不暴露内部 `file_path`；
- **删除**: 登记行与磁盘文件连带删除，删除路径以数据库内 UUID 记录为唯一来源。

4.2 学术翻译（library/translation）

- **状态机**: `queued → running → completed | failed`（仅 failed 可重试）；串行 worker（并发=1）；服务重启时将遗留 running 任务置 failed；
- **sidecar 契约**: 与模板共用 `PAPER_TRANSLATE_PDF2ZH_BIN`（支持 node 包装脚本，1.x/2.x 发行版 CLI 差异全部收敛在包装层）；参数数组 + `shell:false`；密钥仅经环境变量；超时经公共门面杀进程树；
- **优雅关停**: 研究域资源（worker、三库连接）注册进基座 `additionalShutdownSteps`，关停顺序化；
- **产物预览**: mono/dual PDF 经自带 Range 端点输出；双语对照 HTML 内嵌 PDF 改走运行文件代理（见 4.8）。

4.3 论文写作（latex）

- **编译队列**: 文档级串行、并发提交 409 防重入、超时杀进程树、单次结算；服务重启时将遗留 queued/running 编译对账为 failed；
- **错误解析**: 同时解析 tectonic 的 rustc 风格摘要行（容忍 `error:` 前缀）与经典 TeX transcript（`! msg + 1.N`，含文件括号跟踪），输出 `{file, line, message}`；前端错误面板点击后按行号选中源码行；
- **编辑器**: 语法高亮采用"透明 textarea + 高亮层"overlay 方案，高亮复用基座 highlight.js 的 latex 语言（零新依赖）；像素度量（字号/行高/内边距）单源定义并被测试钉死；超 200KB 自动降级；
- **产物**: 编译 PDF 登记进成果注册表。

4.4 知识库 RAG（rag）

- **模型**: collection（成员引用论文库）— 索引任务 — 问答任务三元模型；成员变更使 `indexed → stale`；重启对账清录 running/queued 残留；
- **sidecar 协议**: stdin 单个 JSON（`{action: index|ask, papers, question}`）→ stdout 取最后一个含 `status` 的 JSON 响应（容忍日志横幅污染，2MB 流上限）；`RAG_SIDECAR_BIN` 支持 node 包装脚本/Python/原生二进制；
- **安全**: 子进程环境变量白名单（仅 API 密钥与模型配置，无关机密断言剔除）；缺密钥/未配置 503 快速失败不 spawn；citations 按库成员过滤；

SEU 科研工作台

- **聊天集成**: `POST /rag/chat-asks` 服务端编排——校验 → 确保会话存在 → 追加用户消息 → 问答 → 答案消息落历史; 引用经绑定表 (`question ↔ 消息 id`) 在客户端水合, 刷新与换设备均可溯源; 客户端轮询带 15 分钟护栏与切库终止。

4.5 聊天协同

- **@知识库**: 输入框 @ 提及 (输入法合成结束同步刷新、光标移动保护防前缀复制)、按会话持久化选择 (`localStorage` + 懒校验失效清理);
- **VCP 渲染**: 对 `html / svg / mermaid / math` 围栏渲染沙箱卡片——html 卡 `sandbox="allow-scripts"` (无同源权限)、svg 卡 `sandbox=""` (全隔离)、payload 经编码占位 + 程序化属性赋值 (永不走 v-html 直插)、渲染失败降级代码块; 渲染/美学双开关持久化;
- **产物发送**: 论文/产物经统一弹窗选择会话, 消息体为纯文本 (不含临时令牌、不含会被误判为文件卡片的相对链接)。

4.6 运行文件代理 (run-files)

`GET /api/studio/research/run-files?path=` 将运行产物 (如双语 PDF) 以 Range 流式提供给浏览器内嵌页面。安全链: 绝对路径校验 → 规范化 + 词法 `..` 拒绝 → NTFS ADS 冒号拒绝 → 词法包含性检查 → `realpathSync` (符号链接/junction 逃逸) → 大小写不敏感的包含性复查 → 仅允许 `.pdf` → 越界一律 403/404。

4.7 科研技能 (skillpacks)

- **装载模型**: 技能包 (SKILL.md 资产集) 平铺复制到运行时技能目录, manifest 记录源/装双 sha256; 状态机 `installed / outdated / modified / conflict / missing`;
- **保护语义**: 用户改动 (modified) 不 force 不覆盖; 冲突目录任何情况下不接管; 卸载仅移除 manifest 归属文件;
- **模板集成**: agent 节点声明 `skills: [...]`, preflight 对未装载技能硬拒绝 (409); 流程中心在模板卡片展示技能状态标签, 创建流程时对 missing/outdated 自动装载 (modified/conflict 刻意跳过并警示);
- **profile 校验**: 装载目标 profile 必须属于已知名单, 防任意目录写入。

4.8 成果注册表 (artifacts)

产物登记 (LaTeX 编译 PDF 自动登记; 工作流产出随后续版本接入) → 列表 (类型筛选/关键字过滤) → 元数据预览 (HTML 产物沙箱内嵌) → 删除 (仅移除登记行) → 发送到聊天。响应统一脱敏, 不暴露服务端内部路径。

4.9 通知

工作流运行进入终态时经统一通知设施 (桌面桥 / 浏览器 Notification / Service Worker) 发出系统通知: 跨标签去重 (Web Locks + 共享台账)、前台抑制可选、点击深链至运行详情; 权限未授权时降级为页内提示。

5. 数据模型

各域自有 SQLite 库, 互不共享连接; 建表经统一迁移 (`syncTable → addMissingSafeColumns`), 打开时执行重启对账。

库	主要表	说明
基座 workflows 库	workflows / workflow_runs / workflow_run_node_sessions (含 output_json) / schedules	流程定义、运行快照、节点输出
research/papers.db	papers	文献元数据 (title/original_name/file_size/tags)
research/translation-jobs.db	translation_jobs	翻译任务状态机与产物路径
research/latex.db	documents / compilations	文档、编译记录与错误 JSON
research/rag.db	collections / collection_papers / index_jobs / questions / rag_chat_asks	知识库、索引与问答；绑定表衔接聊天消息 id 与引用
research/artifacts 库	artifacts	产物登记 (id/type/title/version/source_run_id/preview)
技能 manifest	.research-skillpacks.json	源/装哈希与归属，支撑五态与保护语义

6. 安全设计

面	设计
鉴权	全部业务路由挂 JWT 中间件，注册于代理 catch-all 之前；流式/下载类端点支持 ?token= 查询参数（与基座导出下载同模式）
路径安全	用户输入永不拼接文件路径（UUID 存储 / 服务端计算产物路径）；运行文件代理执行"规范化 + realpath + 大小写不敏感包含性 + 扩展名白名单"五重校验；穿越/编码/ADS/符号链接逃逸均有测试
子进程	结构化参数数组 + shell:false ；超时与停止统一杀进程树；输出上限；退出兜底；单次结算防双写
密钥	仅经环境变量注入子进程（白名单构造），不出现在 argv/日志/数据库；无关机密断言剔除
前端注入	VCP 卡片沙箱矩阵（html 无同源、svg 全隔离）；占位符编码 + 程序化 DOM 属性赋值；LaTeX 高亮层先转义后包裹 token
技能目录写保护	哈希归属 + modified/conflict 拒绝覆盖 + profile 白名单

7. 前端设计

- 壳层**：应用侧边栏仅保留科研工作台（一级入口、默认落地）、单聊、工作流、历史、模型配置与设置；品牌名「SEU科研工作台」贯穿标签页/PWA/登录页；
- 研究壳**：五页签共享 ResearchPageShell （页签导航 + 内容槽），各页签独立 Pinia store + API helper（统一经 client.ts 请求封装，流式/下载带令牌）；
- 国际化**：11 种语言（ar/de/en/es/fr/ja/ko/pt/ru/zh/zh-TW），键结构齐平由测试强制（含运行时编译 smoke 与非西文 RTL 逻辑属性检查）；
- 画布**：Vue Flow 承载 DAG；确定性节点卡片支持配置与只读回放，未知类型节点无损往返（仅剥离运行时 UI 字段），无效脚本节点加载期标记、保存期拦截。

8. 质量与测试体系

SEU 科研工作台

层级	规模	说明
服务端研究领域	200+ 用例	各域服务/控制器/存储集成测试（真实 SQLite 与子进程）
引擎	140+ 用例	归一化、生命周期（停止/超时/杀树/超限）、rerun CAS、edge evidence、并行节点
客户端	1670+ 用例	组件挂载/store 动作/路由/i18n 11 语言齐平与运行时编译
端到端	139+ 场景	关键路径真实浏览器验证（mock 后端）
门控真实链路	5 条	pdf2zh 双语、tectonic 编译、paper-qa 问答、python-pptx 导出、翻译队列真实任务（配置环境变量后复跑）

治理机制：工单级评审（实现逐行核对 + 测试复跑）、大阶段外部评审门（A~D）、BC 变更登记、主分支五项回归门禁（研究领域/客户端/e2e/边界/构建）。

9. 部署与运行

- **开发**：`npm run dev`（客户端 8649 / 服务端 8647）；状态目录 `~/.hermes-web-ui`（`HERMES_WEB_UI_HOME` / `HERMES_WEBUI_STATE_DIR` 可覆盖）；
- **关键环境变量**：`TECTONIC_BIN`、`PAPER_TRANSLATE_PDF2ZH_BIN`、`RAG_SIDE CAR_BIN` / `RAG_SIDE CAR_PYTHON`、`RESEARCH_FIGURE_PPTX_PYTHON`、`OPENAI_API_KEY/OPENAI_BASE_URL/OPENAI_MODEL`、`HERMES_LATEX_COMPILE_TIMEOUT_MS`、`PAPER_TRANSLATE_JOB_TIMEOUT_MS`；
- **生产**：`npm run build` 产出客户端静态资源与服务端构建物；桌面形态复用基座 Electron 打包与捆绑运行时（二期启用）；
- **网络受限环境**：`pip` 清华镜像、`HF_ENDPOINT=hf-mirror.com`（pdf2zh 首次布局模型下载）；Python 侧需 ≤ 3.12 （或钉 `numpy<2`）。

10. 演进路线（二期）

方向	内容	价值
技能库深度融入	原版开源科研技能资产（19 个）装载；写作质量检查/AI 痕迹自查/完整性核查确定性节点；论文结构规划模板	智能节点可调用面扩大；主线科研方法全覆盖
绘图自检闭环	figure-drawing 接入引擎 feedback loop：Agent 自检 → 不合格重画（maxIterations）	产出质量迭代
审计节点	过夜科研晨报前接入 61 信号审计确定性检查	长时科研的过程合规审计
知识库性能	落盘/增量索引，大库（数百篇级）响应优化	规模化使用
产物治理	编译/运行产物目录回收策略（保留最近 N 份）	磁盘治理
生产验证与分发	真实 OpenAI 兼容端点回归；桌面安装包；多机部署文档	交付形态完备

11.1 文档索引

文档	位置
项目策划书	docs/research-workbench/项目策划书.md
用户手册（中文）	docs/research-workbench/用户手册.md
模板编写指南	docs/research-workbench/模板编写指南.md
基座改动登记表（BC-1~12）	docs/research-workbench/BASE-CHANGES-REGISTRY.md
任务看板（P0~P10 全记录）	docs/research-workbench/TASKS.md
能力验证报告（spike）	docs/research-workbench/T2.0-spike-report.md 、 T3.2-sidecar-spike.md 、 T3.3-latex-spike.md 、 T4.1-rag-spike.md 、 T4.4-figure-pptx-spike.md

11.2 关键设计决策记录

编号	决策	理由
D1	工作流引擎复用基座 + 确定性节点扩展（方案 C）	复用持久化/快照/审批/调度能力，避免自研引擎的长期维护成本
D2	智能能力 API-first	质量/合规/免本地算力；密钥与端点可替换
D3	确定性脚本与智能节点显式分层	可复现性；失败可见（loud fail）
D4	sidecar 契约收敛于包装层	对外部工具版本演化免疫（pdf2zh 1.x/2.x CLI 差异实证）
D5	聊天 KB 问答服务端编排 + 绑定表水合	历史持久化（用户价值）与基座消息模型零改动的平衡
D6	VCP 沙箱矩阵（html 无同源 / svg 全隔离）	无消毒器依赖下可证明的注入防御

本文档与代码仓库实际状态保持同步。二期演进落地后应修订相应章节并升版。